

1. Υγιεινή Δεδομένων: Διαχείριση Κινδύνου, Όχι Απλή Τακτοποίηση

Data Hygiene as Financial Risk Management | Tidy Data Principles

Η Σιωπηρή Απειλή (Silent Model Distortion)

«*Dirty data almost never crashes a model. It quietly bends one.*»

Τα ακάθαρτα δεδομένα δεν προκαλούν σφάλμα εκτέλεσης (crash). Αντίθετα, αλλοιώνουν ανεπαίσθητα τα αποτελέσματα:

- **Διπλότυπες εγγραφές** → στρεβλή μεταβλητότητα (σ).
- **Κακοπληρωμένα κενά** → πλασματική συσχέτιση (ρ).
- **Look-ahead bias** → ψευδώς κερδοφόρες στρατηγικές.

Τρεις Πυλώνες Αξίας (Value Pillars)

- 1 **Risk Mitigation:** Αποτροπή μόχλευσης (leverage) σφαλμάτων.
- 2 **Reproducibility:** Ασφάλεια επαναληψιμότητας κώδικα.
- 3 **Credibility Capital:** Το πρώτο λάθος νούμερο καταστρέφει οριστικά την αξιοπιστία του αναλυτή.

5 Αρχές Tidy Data (Wickham) στο Finance

Αρχή Tidy Data	Χρηματοοικονομική Παραβίαση
1. Κάθε μεταβλητή σε στήλη	Συσκευασία "USD-Price" σε ένα πεδίο
2. Κάθε παρατήρηση σε γραμμή	Οριζόντια τρίμηνα (Q1-Q4 σε στήλες)
3. Μία μονάδα ανά πίνακα	Trades, accounts & clients σε ένα φύλλο
4. Ατομικές τιμές (atomic)	JSON blob ή λίστα τιμών σε ένα κελί
5. Ρητοί τύποι & ονόματα	Dates ως string, τιμές με \$, Unnamed: 3

Διακυβέρνηση: Human First, Agent Second

Ο Σιδηρούς Κανόνας: Πριν ανατεθεί ο καθαρισμός σε αυτόνομο **Data Quality Agent**, ο αναλυτής οφείλει να γνωρίζει τον χειροκίνητο έλεγχο και να **αξιολογεί στατιστικά** την ποιότητα (eval suite).

2. Το Πρόβλημα του Ημερολογίου & η Ψευδής Απώλεια Δεδομένων

The Multi-Asset Universe & Calendar Alignment Problem (Join Strategies)

Ανομοιογενή Ημερολόγια Συναλλαγών

Στο σύγχρονο FinTech συνδυάζουμε κατηγορίες ενεργητικού με ασύμβατα ωράρια συναλλαγών:

- **SPY (Equities):** Εργάσιμες ημέρες (Business days 'B'), κλειστό Σ/Κ & αργίες ΗΠΑ (2.343 rows).
- **EUR/USD (FX):** Διαπραπτική σύμβαση 5 ημερών (2.425 rows).
- **BTC / ETH (Crypto):** 24/7/365 – συνεχής λειτουργία (3.407 / 3.241 rows).
- **ATHEX:** Τοπικό ημερολόγιο Χρηματιστηρίου Αθηνών (2.315 rows).

Το Δίλημμα της Ενοποίησης (Join Strategy)

1. **Τομή (Intersection / Inner Join):** Κρατά μόνο κοινές ημέρες. Διαγράφει ~ 2/7 της ιστορίας του Bitcoin (αγνοεί ακραίες κινήσεις Σ/Κ!).
2. **Ένωση (Union / Outer Join):** Διατηρεί τα πάντα, αλλά **κατασκευάζει** NaNs σε SPY & EUR/USD κάθε Σαββατοκύριακο (974 κενά).

Κατανομή Ελλειπουσών Τιμών (Missingness Map)

Ημέρα Εβδομάδας	BTC NaNs	SPY NaNs
Δευτέρα – Παρασκευή	0	90 (αργίες ΗΠΑ)
Σάββατο (Saturday)	0	487
Κυριακή (Sunday)	0	487
Σύνολο Σαββατοκύριακου	0	974

Ο Κανόνας του Ελεγκτή (Auditor's Law)

Πριν αναρωτηθείτε «*Με τι να αντικαταστήσω το κενό;*», ρωτήστε:

«Γιατί λείπει;» (Why are you missing?)

Τα κενά του Σ/Κ στις μετοχές δεν είναι βλάβη συστήματος, αλλά **δομική συνέπεια κλειστής αγοράς** (structural non-trading). Επειδή η αιτία είναι παρατηρήσιμη (ημέρα), επιτρέπεται η επιδιόρθωση.

3. Ταξινόμηση Ελλειπουσών Τιμών: Το Πλαίσιο Rubin

Taxonomy of Absence: MCAR, MAR, and MNAR in Financial Data

Η Ιεραρχία Επικινδυνότητας (Rubin's Framework)

Τύπος	Μηχανισμός	Χρηματοοικονομικό Παράδειγμα
MCAR	Αμιγής τύχη. Καμία εξάρτηση από δεδομένα.	Τυχαία στιγμιαία διακοπή δικτύου ή feed glitch.
MAR	Εξαρτάται μόνο από παρατηρήσιμα δεδομένα.	Απουσία τιμών SPY επειδή είναι Σάββατο ($P(\text{missing} \text{Weekday})$).
MNAR	Εξαρτάται από την ίδια τη χαμένη τιμή!	Κατάρρευση ανταλλακτηρίου (Mt. Gox, 2020) λόγω κραχ τιμών.

Επιπτώσεις στην Αντιμετώπιση (Implications)

- **MCAR:** Αμερόληπτη διαγραφή. Κοστίζει μόνο *ισχύ* (efficiency).
- **MAR:** Πλήρως επιδιορθώσιμο υπό συνθήκη. Κοστίζει *κόπο* (effort).
- **MNAR:** **Εξαιρετικά επικίνδυνο!** Κοστίζει την *αλήθεια* (truth).

Πείραμα Ελεγχόμενης Απόκρυψης (BTC 5% Mask)

Δημιουργούμε τεχνητά και τους 3 μηχανισμούς σε πλήρη σειρά:

- Μέση ημερήσια κίνηση $|r_t|$ (όλες οι μέρες): **2.33%**
- Μέση κίνηση σε **MNAR**-κρυμμένες μέρες: **10.57%**

Εξήγηση: Το MNAR κρύβει συστηματικά τις ημέρες ακραίας μεταβλητότητας.

Το Μεγάλο Σφάλμα των Αλγορίθμων

Αν επιδιορθώσετε κενά MNAR με απλή παρεμβολή (interpolation), εξαφανίζετε τα ιστορικά κραχ και **κατασκευάζετε μια ψευδώς ήρεμη αγορά!**

4. Το Πείραμα Απόκρυψης & Οι Μετρικές Αξιολόγησης

The Masking Experiment & Statistical Scorecard (MAE, RMSE, sMAPE, VarRatio)

Το Πρωτόκολλο Απόκρυψης (Masking Experiment)

Πώς ξέρουμε αν ένας καθαρισμός είναι αξιόπιστος;
Όχι κοιτάζοντας το διάγραμμα, αλλά με ποσοτικό έλεγχο:

Hide (Απόκρυψη) → **Repair** (Επιδιόρθωση) →
Compare (Σύγκριση με Answer Key) → **Score**
(Βαθμολόγηση)

Αποτελεί την πρώτη επίσημη **Eval Suite** για AI Agents.

Γιατί sMAPE αντί για MAPE;

$$\text{MAPE} = \frac{1}{|M|} \sum \left| \frac{x - \hat{x}}{x} \right|, \quad \text{sMAPE} = \frac{1}{|M|} \sum \frac{|x - \hat{x}|}{(|x| + |\hat{x}|)/2}$$

Σε αποδόσεις ($r_t \approx 0$), το απλό MAPE εκρήγνυται στο ∞ και είναι ασύμμετρο. Το **sMAPE** είναι συμμετρικό και φραγμένο στο $[0, 200\%]$.

Πίνακας Μετρικών Αξιολόγησης (Scorecard)

Μετρική	Μαθηματικός Τύπος	Ερμηνεία & Ιδιότητα
MAE	$\frac{1}{ M } \sum x - \hat{x} $	Μέσο απόλυτο σφάλμα (σε \$)
RMSE	$\sqrt{\frac{1}{ M } \sum (x - \hat{x})^2}$	Τιμωρεί τα ακραία σφάλματα (RMSE $\geq$ MAE)
VarRatio	$\frac{\text{Var}(\hat{x}_{\text{full}})}{\text{Var}(x_{\text{full}})}$	Διατήρηση Διασποράς: Ιδανική τιμή = 1.00.

Διασπορά vs Ακρίβεια (The Variance Insight)

Ένας αλγόριθμος μπορεί να πετύχει χαμηλό MAE αλλά να ισοπεδώσει τη μεταβλητότητα. Στο finance η **μεταβλητότητα είναι το θεμελιώδες προϊόν** (VaR, option pricing).
Υποεκτίμηση διασποράς (VarRatio < 1) = Επικίνδυνη υποεκτίμηση κινδύνου!

5. Τουρνουά Καταλογισμού & Επιλογή Υπερπαραμέτρων

Univariate Imputation Tournament & Hyperparameter Tuning (Window Sweep)

Οι 5 Οικογένειες Καταλογισμού

- **Constant:** Μέση/Διάμεση τιμή. Καταστροφικό ($RMSE = 32.602$).
- **Directional:** Forward fill (LOCF) / Backward fill.
- **Interpolation:** Γραμμική / Πολυωνυμική παρεμβολή.
- **Rolling Stats:** Κυλιόμενος μέσος/διάμεσος παραθύρου w .
- **Model-based:** Μηχανική μάθηση (KNN, MICE).

Αποτελέσματα Τουρνουά σε 5% MCAR BTC

Μέθοδος	MAE	RMSE	sMAPE%	VarRatio
Linear Interp.	678.07	1,206.82	1.84%	0.9993
Rolling Mean (5)	734.08	1,237.15	2.00%	0.9994
Rolling Mean (3)	703.64	1,265.25	1.90%	0.9994
Polynomial ord 2	760.74	1,297.76	2.12%	0.9994
Forward Fill (ffill)	924.19	1,591.42	2.74%	0.9992
Exp. Smoothing	928.45	1,592.47	2.88%	0.9991
Rolling Mean (60)	1,844.36	2,633.56	6.11%	0.9995
Global Median	25,416.37	32,602.79	75.49%	0.9609

Βελτιστοποίηση Παραθύρου w (Hyperparameter Tuning)

Η επιλογή παραθύρου στα rolling statistics είναι κλασικός συμβιβασμός:

- **Μικρό w ($w < 3$):** Ευαισθησία στον τοπικό θόρυβο.
- **Μεγάλο w ($w \geq 30$):** Καθυστέρηση προσαρμογής (staleness). Σε ανοδική τάση, ο μέσος 60 ημερών μένει συστηματικά πίσω.
- **Εμπειρικό Βέλτιστο:** Ελάχιστο RMSE στο $w = 5$ ημέρες ($RMSE = 1.237, 15$).

Τελική Ετυμηγορία Μονομεταβλητής Ανάλυσης

Η **Linear Interpolation** αναδεικνύεται νικητής ακρίβειας για ιστορική μελέτη, καθώς η χρονική συνέχεια (temporal continuity) σε ημερήσια κενά είναι κυρίαρχη.

6. Το «Έγκλημα» Πρόβλεψης Μέλλοντος & Πολυμεταβλητά Μοντέλα

The Look-Ahead Crime & Multivariate Tournament (KNN, MICE, Cost Ledger)

The Look-Ahead Crime & $\mathcal{F}_t$ -Μετρησιμότητα

Μια μέθοδος είναι αποδεκτή σε **πραγματικό χρόνο** (real-time trading) MONO αν χρησιμοποιεί πληροφορία διαθέσιμη τη στιγμή t ($\mathcal{F}_t$ -measurable):

- **Linear Interp:** Χρησιμοποιεί την τιμή της επόμενης Δευτέρας → **Look-ahead bias!** Παράγει πλασματικά κέρδη σε backtests.
- **Forward Fill (ffill):** Η μόνη νόμιμη μέθοδος σε real-time.

Επίπτωση Καταλογισμού Σ/Κ (SPY / BTC)

Ημερολόγιο	Μέση Απόδοση	Μεταβλητότητα σ	Συσχέτιση BTC
Intersection	0.0006	0.0117	0.2837
Union (ffill)	0.0004	0.0097	0.2680
Union (linear)	0.0004	0.0089	0.2593

Το ffill παράγει 0% αποδόσεις το Σ/Κ, συμπιέζοντας τεχνητά μεταβλητότητα και συσχέτιση!

Πολυμεταβλητό Τουρνουά (5-Asset Panel)

Εκμετάλλευση διαστρωματικής συσχέτισης ($|\bar{\rho}| = 0.525$):

Μοντέλο	MAE	RMSE	Χρόνος (sec)
Linear Interp.	0.0279	0.0444	0.0010
KNN ($k = 5$)	0.0785	0.1489	0.0380
KNN ($k = 10$)	0.0851	0.1541	0.0398
MICE	0.3856	0.5501	0.0668
Column Mean	0.8568	1.0194	0.0016

Cost-Ledger Memo (Ανάλυση Κόστους)

- Τα KNN/MICE είναι $40 \times - 70 \times$ πιο αργά υπολογιστικά.
- Σε 5 χαλαρά συσχετισμένα assets, η χρονική εγγύτητα (linear) υπερτερεί της διαστρωματικής πληροφορίας.
- Τα KNN/MICE υπερτερούν σε πυκνά πάνελ (> 200 μετοχές ίδιου κλάδου με υψηλή συσχέτιση).

7. Από την Υγιεινή στη Διακυβέρνηση: Cleaning Agent Rulebook

AI Governance & The 10 Executable Assertions (Rulebook v1.0)

Το Καταστατικό του AI Agent: Rulebook v1.0

#	Εκτελέσιμος Κανόνας	Σκοπός & Αιτιολόγηση	Status
R1	Unique & sorted dates	Αποφυγή διπλομετρήσεων & αταξίας	PASS
R2	Zero missing cells	Πλήρης κάλυψη πίνακα	PASS
R3	Strictly positive prices	Αποτροπή κατάρρευσης log-returns	PASS
R4	No future timestamps	Έλεγχος σφαλμάτων ($\leq$ today)	PASS
R5	Daily log return $\leq$ 50%	Εντοπισμός λαθών υποδιαστολής	PASS
R6	VarRatio $\in$ [0.80, 1.20]	Αποτροπή υπερ-λειάνσης	PASS
R7	Unique columns	Αποφυγή διπλών σειρών assets	PASS
R8	Finite values only	Αποκλεισμός $\pm \infty$ & NaN	PASS
R9	$\geq$ 95% rows retained	Αποτροπή σιωπηρής διαγραφής	PASS
R10	No zero prices	Μηδενικές τιμές είναι άκυρες	PASS

Ετυμηγορία Ελέγχου (Auditor Verdict)

Αποτέλεσμα: 10 / 10 Κανόνες πέρασαν επιτυχώς.

Τελική Απόφαση: **ACCEPTED**.

«Ένα dataset που πέρασε από εκτελέσιμο rulebook υπερτερεί οποιουδήποτε θεωρητικά τέλειου dataset που δεχτήκατε τυφλά.»

Βέλτιστες Πρακτικές Παραγωγής (Production Stack)

- **Polars (Rust Engine):** 27x ταχύτερη επεξεργασία και lazy execution σε τεράστια πάνελ ($> 10^7$ γραμμές).
- **Parquet Format:** Αποθήκευση schema, αυστηρών τύπων δεδομένων (types) και συμπίεσης. Τέλος στα σφάλματα re-parsing των CSVs!
- **Data Quality Gatekeeper:** Ο AI Agent εκτελεί ενέργειες, αλλά ο ανθρώπινος αναλυτής ορίζει τους κανόνες αποδοχής.